Piloto R0: o que as avaliações dos juízes mostraram

Reunião de calibração, 06/11/2026. Material de diagnóstico. 3 de 4 juízes avaliaram às cegas o mesmo par de fichamentos. Cada juiz viu o par com **orientação A/B sorteada**. As tabelas abaixo já estão **realinhadas por fichamento**, não pela letra que cada um viu.

	Fichamento 1	Fichamento 2
cobertura	8 conceitos + 5 achados	1 conceito + 1 achado
autoria	Respondente 1	Respondente 2

Notas BARS por seção e juiz

Fichamento 1: alta cobertura

seção	Juiz 1	Juiz 2	Juiz 3	range
resumo executivo	4	6	2	**4**
questão de pesquisa	1	3	2	2
teorias	5	4	4	1
conceitos-chave	6	2	5	**4**
metodologia	4	5	4	1
achados	6	6	4	2
contribuição	6	6	4	2
total	**32**	**32**	**25**	

Fichamento 2: baixa cobertura

seção	Juiz 1	Juiz 2	Juiz 3	range
resumo executivo	3	2	2	1
questão de pesquisa	1	1	1	0
teorias	4	4	2	2
conceitos-chave	3	4	1	3
metodologia	3	4	3	1
achados	1	3	2	2
contribuição	2	2	2	0
total	**17**	**20**	**13**	

Como ler

1. **A régua concorda no piso.** No Fichamento 2, 10 de 14 células ficaram com range de no máximo 2 pontos; `questão` = 1 e `contribuição` = 2 foram **unânimes**. Ninguém deu mais que 4. Fichamento fraco é reconhecido como fraco por todos. A escala discrimina bem na ponta baixa.
2. **A régua disputa na zona "completo porém impreciso".** No Fichamento 1, `resumo` e `conceitos` abrem range 4. E as qualitativas mostram que não é ruído: é **desacordo de critério**. Um juiz pune reprodução literal e confusão citar/discutir; outro paga completude mesmo vendo invenções; o terceiro fica no meio.
3. **É exatamente a zona da R1.** O fichamento de IA tende a ser completo, fluente e com erros sutis. Vai cair nessa célula. Se a âncora não definir o trade-off fidelidade × cobertura, a comparação IA×humano mede a opinião do juiz, não a qualidade.

O que os juízes escreveram (sinais qualitativos)

- **Citar ≠ discutir.** Dois juízes levantaram o mesmo ponto sem se consultar: vereditos `discute` dados a teorias apenas citadas na revisão; esquema de estruturação marcado `usa` quando é só mencionado.
- **Reprodução literal ≠ síntese.** "Fiel porque cita partes literais do texto, mas isso não garante precisão"; resumo descrito como "colcha de retalhos do artigo".
- **Inflação de contribuição.** Um juiz chamou o Fichamento 1 de "superinflado" e ainda assim deu 6: a fronteira entre as âncoras 4 e 7 estava solta.
- **A questão implícita.** O artigo-piloto não enuncia a pergunta; um juiz puniu os dois fichamentos por não *sinalizarem* essa ausência.
- **Preferência vs. soma das notas.** Um juiz deu total maior a um lado e declarou **empate**: "nenhum dos dois é suficientemente preciso". Coerente com a pergunta "qual você usaria?", mas vale explicitar a regra.
- **Viés de expectativa em flagrante.** Um juiz anotou que o Fichamento 2 "foi feito por humano" e o 1 "foi feito por IA". **Os dois são de estudantes.** A "IA" imaginada era um estudante. E os defeitos atribuídos a ela (reproduzir, extrapolar) eram exatamente os que o juiz pune. O cego funcionou; a teoria-de-IA do juiz, não.

A pergunta que a reunião responde

> Diante de um fichamento **completo porém impreciso**, quanto vale a completude quando a fidelidade falha? É o Item 1 da proposta.