PROPOSTA — Medição de aprendizagem dos estudantes

> ***Status: sugestão para discussão com os autores. NÃO implementada no protocolo/schema.***
> *Adicionar qualquer módulo exige decisão antes da Rodada 1 (instrumento congelado) — idealmente entra no pré-registro OSF.*

Racional

O desenho final do pipeline é "IA ficha → humano revisa". Logo, a habilidade crítica do estudante não é só *produzir* fichamentos, mas **julgar a qualidade de um fichamento** (detectar alucinação, omissão, etc.). Medir aprendizagem = medir evolução dessa competência avaliativa, além da produtiva.

Módulo A — Calibração metacognitiva (auto-avaliação)

- **O quê**: estudante auto-atribui nota BARS 1–7 por seção ao próprio fichamento antes de submeter.
- **Medida**: `|auto-nota − média dos juízes|` por seção → gap de calibração; trajetória R1→R2 mostra se o estudante aprende a *julgar* melhor o próprio trabalho.
- **Custo**: ~2 min/fichamento.
- **Impacto no schema**: campo opcional `self_assessment` em `generator` (human) — 7 inteiros 1–7.
- **Literatura**: metacognitive calibration (ICLS 2023 — ver REFERENCES.md §D); literatura prevê piores performers = mais sobre-confiantes → hipótese testável.

Módulo B — Teste de detecção de erros (transfer test)

O quê: pré-R1 e pós-R2, cada estudante revisa um fichamento com erros *plantados* da taxonomia (`hallucination`, `omission`, `misinterpretation`, `invalid_source_ref`…). Mede taxa de detecção + falsos positivos.

Por que é forte: é literalmente o teste de proficiência da tarefa final do protocolo — revisar saída de IA. Se o checklist da calibração funciona, a taxa de detecção deve subir do pré para o pós.

Como se parece o instrumento

- Um artigo **fora do corpus** (ninguém ficha ele no estudo) — evita contaminação.
- Um fichamento construído pelos pesquisadores com ~10 erros conhecidos, um por código da taxonomia, com a resposta-chave registrada em arquivo privado (`data/learning/error-spotting-key.json`).
- Duas versões contrabalançadas (erros diferentes no mesmo artigo, ou dois artigos): metade dos estudantes recebe a versão X no pré e Y no pós — controla efeito de memorização do item específico.

- Tarefa do estudante: "marque os problemas que encontrar e classifique-os" — mesmo vocabulário da rubrica que os juízes usam.

Medidas

métrica	definição
taxa de detecção	erros encontrados / erros plantados
falsos positivos	flags que não correspondem a erro plantado
especificidade	detecção por código de erro (ele pega alucinação mas não omissão?)

(Sem medida de tempo na tarefa B: auto-reportada em tarefa curta é ruidosa e incentivaria pressa artificial.)

Custo e agenda

- ~30–45 min por aplicação × 2 (pré-R1, pós-R2).
- Trabalho de preparação: construir o fichamento plantado + chave — ~1 dia de trabalho dos pesquisadores, fora do pipeline automático.

- **Não precisa estar pronto sexta**: o pré pode ser aplicado na primeira semana da R1, antes dos primeiros fichamentos.

- **Impacto no schema**: novo arquivo `data/learning/error-spotting-*.json` (não toca fichamento.schema).

Módulo C — Trajetória por estudante (custo zero)

- **O quê**: curva individual de notas BARS × ordem de fichamento; `elapsed_minutes` × qualidade; evolução do perfil de erros por código.
- `elapsed_minutes` **= tempo total estimado** (leitura + fichamento), auto-reportado por artigo. Leitura principal: **métrica econômica** — custo-tempo humano por fichamento, comparável depois ao tempo/custo de geração+revisão com IA ("economia de tempo da IA"). Uso secundário: covariável descritiva na trajetória de aprendizagem.
- **Já está nos dados** — só exige código de análise (incluir no `fichamento analyze` se aprovado).

Módulo D — Log de reflexão (qualitativo)

- 3 perguntas abertas por fichamento: o que foi difícil / o que aprendeu / o que faria diferente. Codificação temática → evidência qualitativa.
- **Momento**: imediatamente após submeter cada fichamento, no mesmo formulário de entrega — antes de qualquer retorno dos juízes (o log deve refletir a experiência de produção, não a nota recebida).
- Alternativa de menor carga: 1 log por rodada — perde a granularidade por artigo que conecta o relato ao perfil de erros.

Ressalva metodológica

Com ~3 fichamentos/estudante/rodada, trajetórias individuais são **exploratórias/descritivas** — não sustentam inferência estatística. Reportar como tal; o valor está nos padrões, não em p-valores.

O desenho JÁ é pré/pós (insight do pesquisador, 2026-10-12)

As duas rodadas já são estruturalmente um **pré-teste → intervenção → pós-teste**: a calibração (checklist de estudantes + refinamento do prompt) é a intervenção. Isso sugere reframing elegante para o paper: **calibração simétrica** — o protocolo calibra a máquina (prompt) e o humano (checklist); medir aprendizagem = medir o efeito da calibração humana. Pergunta extra "de graça": *o protocolo calibra melhor a máquina ou o humano?*

Confounds e mitigações

risco	mitigação
checklist vs. maturação (prática sozinha já melhora)	(a) reportar efeito bundado "prática+checklist" como descritivo; (b) análise por código de erro — se o checklist mira omissões e só omissões caem, é evidência de efeito específico; (c) split-half (5 recebem, 5 não) se quiserem claim causal — custa n e simetria
dificuldade dos artigos difere entre rodadas	sortear alocação artigo→rodada com seed registrada (ver PROTOCOL §2) — necessário independentemente deste módulo
n pequeno por estudante	reportar trajetórias individuais como descritivas; testes só no agregado

Recomendação (proponente)

Pacote mínimo: A + C + D — ~3 min/fichamento de custo total, alto alinhamento com o objetivo final do projeto. **B é o stretch goal**: o teste mais direto da competência-alvo, mas exige ~1 dia de preparação e 2× ~40 min dos estudantes; o pré pode ser aplicado na primeira semana da R1, então não é blocker para a reunião de sexta — mas a decisão de incluí-lo precisa sair nessa reunião, pois é o único módulo que exige coleta extra *antes* dos fichamentos começarem.